

16 a 19 de Outubro de 2017
Instituto Politécnico - Universidade do Estado de Rio de Janeiro
Nova Friburgo - RJ

IDENTIFICAÇÃO DE VASOS SANGUÍNEOS EM IMAGENS DA RETINA

Breno Peixoto dos Santos¹ - breno.peixoto.santos@gmail.com

João Victor de Oliveira Novaes¹ - j.victoresp@gmail.com

Wagner Ferreira de Barros¹ - wagner.barros@ifnmg.edu.br

¹Instituto Federal do Norte de Minas Gerais - Campus Montes Claros, MG, Brazil

Resumo. *Este trabalho apresenta um algoritmo para a segmentação dos vasos sanguíneos a partir de imagens de retina, o qual tira proveito de técnicas simples, mas poderosas de processamento de imagens. O algoritmo proposto usa o espaço de cores CIELAB para trabalhar no canal de luminância e apresenta um método iterativo para aprimoramento de contraste e um método simples para extração de fundo e limiar de imagem usado no processo de binarização. Os resultados mostram que a nossa metodologia funciona melhor ou equivalente a outros métodos conhecidos em termos de precisão e eficiência.*

Palavras-chave: *Imagem da retina, Processamento de imagens, Segmentação de imagens*

1. INTRODUÇÃO

É crescente o uso de técnicas presentes na Ciência da Computação em processos de automatização de tarefas. Tais técnicas ocupam um papel cada vez mais importante na sociedade auxiliando a humanidade no desenvolvimento das suas tarefas.

Da mesma forma, vale ressaltar a presença de tais técnicas também na área médica. Assim, este trabalho aborda a utilização de um conjunto de técnicas de processamento digital de imagens, para detecção de vasos sanguíneos em imagens do fundo do olho, ou seja, da retina. Segundo de Oliveira (2013) e Soares (2006), imagens do fundo do olho podem ser utilizadas para descobrir diversas doenças oculares ou sistêmicas, tais como diabetes e hipertensão, aterosclerose e outras doenças cardiovasculares. Tais trabalhos, ressaltam a importância da detecção de vasos sanguíneos não só pelas doenças oculares e cardiovasculares, mas também por apresentarem dicas de como está a saúde vascular de todo o corpo do paciente.

Mendonça and Campilho (2006) afirmam que, quando a rede de vasos sanguíneos é muito extensa, torna-se cansativo e, em alguns casos, impossível a detecção dos vasos por seres humanos. Devido a estas características, um método automático e confiável de detecção se torna uma excelente ferramenta para o auxílio ao diagnóstico médico.

Segundo Wu et al. (2006) Dentre os principais desafios encontrados no processo de detecção automática de vasos em imagens da retina encontram-se: lesões nos vasos, alterações patológicas e o baixo contraste dos vasos capilarizados. Mendonça and Campilho (2006) exemplificam

tais dificuldades expondo a situação de exsudatos duros, que são manchas e pontos brancos causados por retinopatia diabética. Os Exsudatos duros modificam o gradiente alterando a direção e a intensidade das cores na imagem, sendo que eles podem ser segmentados como vasos sanguíneos, dependendo do tipo de técnica utilizada.

A Fig. 1, coloca lado a lado uma imagem do fundo de olho e o resultado de um processo manual de segmentação dos vasos sanguíneos observados, ou seja, realizado por um observador humano.




Figura 1- À esquerda uma imagem obtida a partir de um exame de retinografia e, à direita, o resultado de um processo manual de segmentação dos vasos sanguíneos encontrados na imagem da esquerda. Fonte: Imagens Base DRIVER Staal et al. (2004).

Dentre as diversas técnicas utilizadas para realizar a segmentação de vasos sanguíneos em imagens da retina, para este trabalho iremos destacar duas técnicas: aquelas que utilizam classificadores estatísticos e aprendizado de máquina, e aquelas que utilizam equalização de histogramas e binarização de imagens. Para isto, foram selecionados os trabalhos propostos por Soares (2006) e Saleh et al. (2011), respectivamente.

Soares (2006) utiliza um método de classificação supervisionada. Primeiramente, a imagem é pré-processada utilizando *Wavelets de Gabor 2D* (Daugman, 1980), um método estatístico, para remoção de ruídos e detecção de bordas. Após o pré-processamento é utilizado como classificador o KNN com 8 vizinhos, proposto por (Duda et al., 2001). Usando esta metodologia os autores obtiveram uma média de 95% de acertos nas imagens, porém, o tempo de execução do algoritmo superou o total de 4 horas para realizar a classificação, sendo que a base era composta por apenas 40 imagens. Além do mais, por se tratar de um método supervisionado, torna-se necessário a intervenção humana para indicar ao algoritmo qual classificação era aceita ou não.

Saleh et al. (2011) utilizam um método iterativo para realizar um processo adaptativo para realizar expansão de contraste a partir de equalização de histograma. No algoritmo proposto, primeiro a imagem é convertida para tons de cinza e, ao mesmo tempo, utiliza-se também a banda G da imagem original RGB. Posteriormente, é aplicado o processo de melhoria do

contraste para depois realizar a extração do fundo e, finalmente, é desenvolvido um método iterativo, chamado *ISODATA*, para realizar a binarização da imagem. Com algoritmo proposto, os autores obtiveram em média 95,5% de acerto quando utilizando a imagem convertida para tons de cinza, e uma média de 96,3% ao utilizar a banda G da imagem RGB de entrada.

Neste trabalho é utilizado um conjunto de técnicas de processamento digital de imagens para segmentar de forma automática os vasos sanguíneos de imagens do fundo do olho. Dentre as técnicas utilizadas encontram-se, a conversão e análise da imagem em um espaço de cores mais adequado ao procedimento, a saber, foi escolhido o espaço de cores $L^*a^*b^*$, ou CIE-LAB, cujos detalhes serão dados na Seção 2.2, técnicas de melhoria do contraste, suavização e remoção do fundo observando-se apenas a luminância da imagem da entrada, uma técnica simples de binarização e um operador morfológico para remover objetos conectados menores que um determinado tamanho (estabelecido empiricamente). Para testar o algoritmo desenvolvido, utilizou-se um subconjunto de imagens presente na base de dados DRIVE, (Staal et al., 2004), das quais se dispunha de resultados de referência obtidos por um processo manual. Para fins de comparação, os resultados obtidos foram comparados com outros dois métodos presentes na literatura, (Soares, 2006; Saleh et al., 2011). O método proposto apresentou uma média de acertos muito próxima a ambos os métodos, porém, com redução significativa no tempo de execução e nos valores médios calculados de falsos positivos e falsos negativos.

2. MATERIAIS E MÉTODOS

Nessa seção serão apresentados alguns conceitos e justificativas para escolhas dos métodos utilizados.

Uma visão geral do algoritmo proposto pode ser observado no fluxograma da Fig. 2.

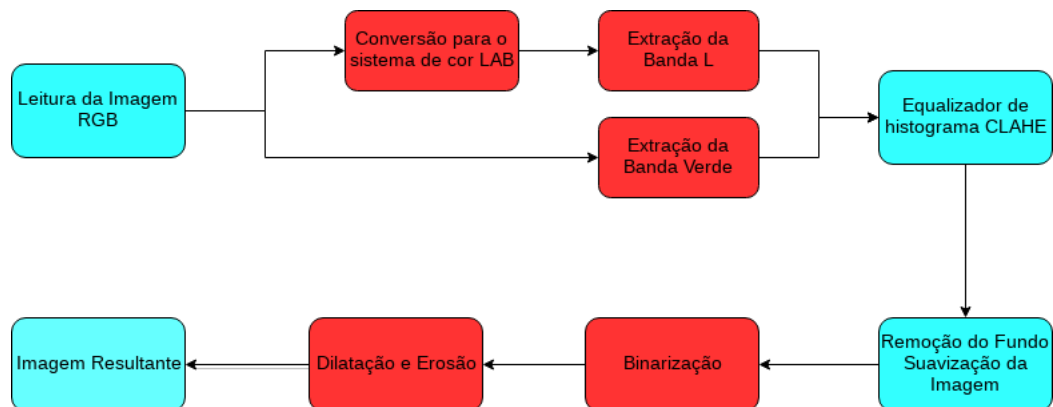


Figura 2- Fluxograma do algoritmo proposto.

2.1 Base de dados

Para testar a metodologia proposta neste trabalho, foi utilizada a base de dados DRIVE (Staal et al., 2004), por tratar-se da base de dados mais comumente utilizada em trabalhos desta natureza.

A base de Dados DRIVE é composta por 40 imagens, tendo 7 delas lesões, e ela vem acompanhada de duas bases com segmentação manual(feita por pessoas diferentes). As imagens

foram escolhidas aleatoriamente em um programa de triagem de retinopatia diabética na Holanda. Todas as imagens estão em formato RGB com tamanho de 768x584, tendo 8 bits por canal de cor.

A segmentação manual aconteceu para 20 imagens e, assim como nos trabalhos estudados, será aplicada a técnica proposta nas imagens com segmentação manual que serão utilizadas como imagens de referência. Os resultados obtidos também serão confrontados com os trabalhos propostos por Soares (2006) e Saleh et al. (2011).

2.2 Espaço de cores

O espaço de cores padrão de uma imagem é o RGB. No modelo RGB, cada cor aparece em seus componentes espectrais primários de vermelho (R), verde (G) e azul (B), (Gonzalez and Woods, 2014). Entretanto, para fins de segmentação de imagens coloridas, o espaço RGB nem sempre é o mais adequado. Neste trabalho, optou-se por escolher um espaço de cores capaz de separar as informações presentes na luminância da crominância. Por outro lado, devido às características das imagens a serem segmentadas e, conforme observado por Saleh et al. (2011) e de Oliveira (2013), também foi utilizada a banda G do modelo RGB para fins de comparação.

Para realizar a separação entre a luminância e a crominância da imagem de entrada, foi escolhido o espaço de cores $L^*a^*b^*$ ou CIELAB, especificado por Consortium (2004). Assim como o espaço RGB, o CIELAB também possui três canais, porém o primeiro canal L^* é composto pela luminância (ou de forma mais simples, o brilho percebido pela câmera), enquanto que, os demais canais compõem a informação da crominância tendo-se como base a teoria das cores opostas, onde duas cores não podem ser verdes e vermelhas ao mesmo tempo, ou amarelas e azuis ao mesmo tempo. Assim, o canal a^* é uma composição de verde para vermelho, enquanto que, o canal b^* é uma composição do azul para amarelo. A Fig. 3 ilustra melhor seu significado deste espaço de cores.




Figura 3- Descrição visual do espaço de cores LAB. Imagem obtida de <https://nixsensor.com/blog/how-do-you-measure-color-accuracy>, último acesso em 15/08/2017.

A Fig. 4 mostra uma imagem de fundo de olho no sistema RG e as imagens resultantes da extração dos canais G e L.

Ao observar estas imagens, é possível perceber com maior evidência os vasos sanguíneos presentes. Entretanto, para realização da segmentação automática, ainda torna-se necessário fazer uso de alguma técnica de ajuste de contraste para realçar os vasos sanguíneos, uma vez que, alguns dos vasos podem apresentar uma tonalidade muito próxima daquela presente no fundo da imagem.



Figura 4- Imagem com todos os canais utilizados no trabalho.

2.3 Contraste

O contraste entre dois objetos pode ser definido como a razão entre os seus níveis de cinza médios. Baixo contraste acontece por diversos motivos, dentre eles destacam-se: diferença de condições de iluminação entre as fotos, não linearidade ou pequeno alcance do sensor (Saleh et al., 2011), excesso de ruído, desfocagem, etc.. Goatman et al. (2003) constataram que a adaptação do histograma é a melhor forma de definir este problema e fazer o reajuste durante o pré-processamento.

Cree et al. (2005) ressaltam que, para melhorar o contraste o melhor método é dividir a imagem em pequenos quadros e, a partir disso, calcular a média, dessa maneira o valor encontrado em cada quadro é mais significativo para os pixels daquele quadro do que quando é feito o ajuste pela análise de toda a imagem. Em Soares (2006), a melhoria do contraste foi realizada pela função *adapthisteq* presente no MATLAB®, conforme descrito a seguir:

“Aumenta o contraste da imagem em escala de cinza I, transformando os valores usando o equalizador de histograma adaptativo com contraste limitado - CLAHE¹.

CLAHE opera em pequenas regiões na imagem, chamados quadros, em vez de toda a imagem. O contraste de cada bloco é aprimorado, de modo que o histograma da região de saída coincida aproximadamente com o histograma especificado pelo parâmetro 'Distribuição'. Os quadros vizinhos são então combinados usando uma interpolação bilinear para eliminar limites induzidos artificialmente. O contraste, especialmente em áreas homogêneas, pode ser limitado para evitar a ampliação de qualquer ruído que possa estar presente na imagem.”²

(MATLAB, 2017)

2.4 Binarização

Segundo (Moreira, 2011), a binarização consiste em achar um limiar em um histograma que melhor separa as fases presentes neste histograma. Este limiar servirá de base para modificar a

¹CLAHE - contrast-limited adaptive histogram equalization.

²Tradução feita pelos autores

imagem de forma que, todos valores superiores ao limiar se tornem 1 (um) e todos os valores que se encontram abaixo do limiar se tornem 0 (zero). Esta técnica é utilizada principalmente para remoção de fundo de imagem, e em imagens onde a forma tem mais relevância que as cores. Tal procedimento se aplica a imagens em tons de cinza.

$$IB_{i,j} = \begin{cases} 0, & \text{se } I_{i,j} \leq Th \\ 1, & \text{se } I_{i,j} > Th \end{cases} \quad (1)$$

A Eq. 1 mostra a regra para a limiarização, sendo que, $IB_{i,j}$ é a imagem binarizada e Th o limiar para a binarização. A Seção 2.5 descreve o processo para obtenção do limiar.

Neste trabalho a binarização é utilizada como separador dos vasos das demais estruturas. Assim, após o processo, os vasos terão valor 1 (brancos), enquanto que as demais regiões estarão com o valor 0 (preto).

2.5 Definição do limiar

Foi utilizada a função *graythresh* do MATLAB® para definição do limiar Th . Esta função utiliza o método de Otsu, (Otsu, 1979). Segundo Bertholdo (2007), o método de Otsu determina o limiar de acordo com a variância entre as classes, e sua fórmula geral pode ser descrita por:

$$\sigma_c^2(i, j) = \sigma_1^2(P1) + \sigma_2^2(P2) \quad (2)$$

$$Th = \min_{0 \leq (i,j) \leq TAM-1} \sigma_c^2(i, j) \quad (3)$$

Em 2, $P1$ e $P2$ são as classes (0 e 1 respectivamente), $\sigma_c^2(i, j)$ é a soma da variância do pixel(i, j) em relação a $P1$ e da variância do pixel(i, j) em relação a $P2$.

Pelo método de Otsu o Th utilizado como limiar para a binarização será o mínimo de todos os $\sigma_c^2(i, j)$ (Gazziro and Borges, 2017).

2.6 Subtração do fundo

Uma das etapas necessárias ao algoritmo proposto é a remoção do fundo da imagem para evidenciar os vasos sanguíneos. Para isto, é proposta uma metodologia simples que consiste em evidenciar os elementos de alta frequência, subtraindo da imagem os elementos de baixa frequência. A ideia central desse algoritmo consiste em encontrar um valor médio em uma vizinhança pré-definida formando assim uma região que pode ser subtraída, (Saleh et al., 2011).

$$\mathcal{G}(i, j) = \frac{1}{LXC} \sum_{n=1}^{LXC} g_n \quad (4)$$

Em Saleh et al. (2011) é dito que a utilização de uma janela 9×9 retorna os melhores resultados para esse tipo de aplicação. Neste trabalho isto também pôde ser observado. Sendo que, quando se aumenta o tamanho da janela, perde-se informação da imagem, enquanto que, ao reduzir o tamanho não se consegue retirar o fundo com a mesma eficácia.

2.7 Operadores morfológicos

Neste trabalho são utilizados alguns operadores morfológicos para filtrar os resultados obtidos após o processo de binarização. Tais operadores são provenientes da morfologia matemática. Welfer (2011) define que os principais componentes da morfologia matemática são os elementos estruturantes. Um elemento estruturante é um conjunto de objetos bem definido, do qual se sabe a forma e o tamanho, normalmente a forma do elemento estruturante é baseada em alguma estrutura geométrica (linhas, discos, dentre outros). O uso destes elementos em uma imagem, permite extrair informações sobre a geometria e a topologia da imagem (Welfer, 2011).

Segundo de Oliveira (2013), os operadores morfológicos mais básicos são os de erosão (ε) e dilatação (δ). Uma operação de erosão em uma imagem A por um elemento estruturante B , pode ser definida como sendo uma operação que reduz o tamanho dos conjuntos de pixels da imagem A . Os pixels resultantes desta operação, são todos os pixels de A que, quando transladados por B , ainda pertencem a A , (Neto, 2010; Facon, 2011), ou seja, dado um centro (x, y) de um elemento estruturante B , a operação de erosão apaga todos os pixels da vizinhança de (x, y) , que translados por B , não estarão mais contidos no domínio da imagem. A Equação 5 apresenta uma notação matemática para uma operação de erosão.

$$\varepsilon^{(B)}(A) = \{(x, y) : B + (x, y) \subseteq A\} = \{x : Bx \subseteq A\} \quad (5)$$

De uma forma simples, a dilatação binária divide a imagem em pequenas regiões. Tendo-se um determinado ponto central g em cada região e, a partir desse ponto, uma função f previamente definida, percorre-se a vizinhança desse ponto. Se, pelo valor da função, o pixel for considerado relevante ele fará parte da imagem resultante, caso contrário, ele será removido Facon (2011). A Eq. 6 traz a definição matemática da dilatação.

$$\delta^g = x \in f : g(i, j) \cap f \neq \emptyset \quad (6)$$

Uma outra operação morfológica conhecida é a operação de abertura. Ela é definida como a combinação de uma operação de erosão seguida de uma operação de dilatação, ambas pelo mesmo elemento estruturante (Welfer, 2011). A Eq. 7 define a operação de abertura. Ao se utilizar uma operação de abertura define-se um tamanho para o elemento estruturante, como resultado desta operação, todos os conjuntos de pixels que são menores que o elemento estruturante são removidos da imagem (MATLAB, 2017).

$$\gamma^{(B)}(A) = \delta^{(B)}(\varepsilon^{(B)}(A)) \quad (7)$$

Neste trabalho, após a binarização, foi utilizada uma operação morfológica de abertura, para remover ruídos provenientes da binarização e da remoção do fundo, o tamanho do elemento estruturante que gerou os melhores resultados nesta etapa foi de 8 pixels.

3. RESULTADOS

O algoritmo foi escrito e testado com a IDE MATLAB2012a em um computador intel core i5-2430M CPU 2.40GHz 4GB RAM, utilizando o sistema operacional LINUX FEDORA24.

A utilização da Luminância do espaço de cores CIELAB gerou resultados satisfatórios, a Fig. 5 exibe à esquerda uma imagem onde os vasos sanguíneos foram extraídos manualmente por uma pessoa do 1º grupo (aqui chamado manual 1), no meio temos uma outra imagem com vasos extraídos manualmente por uma pessoa do 2º grupo (manual 2), e à direita temos a imagem com vasos extraídos pela metodologia proposta neste trabalho.




Figura 5- Comparativo entre as segmentações manuais e a segmentação obtida a partir da banda *L* na metodologia proposta.




Figura 6- Gráfico de acertos em relação às segmentações manuais.

Como resultado da metodologia utilizada, a banda *L* do espaço CIELAB obteve em média 95,1% de acertos em comparação com a primeira extração manual e 95,5% em comparação à

segunda extração manual. Sendo a média geral de acertos igual a 95,3%. Vale ressaltar que, em alguns casos foram obtidos valores superiores a 96%, como pode ser observado no gráfico da Fig. 6.

É possível observar que a metodologia proposta obteve uma proporção semelhante de falsos negativos, 4,1% em média, quando comparado à metodologia proposta em Saleh et al. (2011), porém, a porcentagem obtida de falsos positivos reduziu significativamente, ficando abaixo de 0,6%, quando comparado com o trabalho proposto por (Saleh et al., 2011), que obteve valores superiores a 8%. O tempo de execução corresponde ao tempo necessário para executar o algoritmo em todas as imagens da base de dados utilizada (total de 40 imagens).

Tabela 1- Tabela comparativa com os trabalhos relacionados. As colunas *Prop. LAB* e *Prop. Green* correspondem aos resultados obtidos no trabalho proposto. As colunas *S. Green* e *S. Gray-scale* são resultados do trabalho de Saleh et al. (2011), e a coluna *Soares* do trabalho de Soares (2006).

	Prop LAB	Prop Green	S Green	S Gray-scale	Soares
Media de acertos base 1 (%)	95,1	95,3	-	-	-
Media de acertos base 2 (%)	95,5	94,9	-	-	-
Media de acertos Geral (%)	95,3	95,1	95,5	96,6	94,6
Falsos Positivos(%)	0,53	2,4	8,3	8,4	-
Falsos Negativos(%)	4,1	1,8	3,1	3,4	-
Tempo de Execução (min)	0,1	0,1	-	-	240

4. CONCLUSÕES

Pode-se concluir que a metodologia proposta nesse trabalho atingiu o objetivo de ser uma ferramenta eficiente para a detecção de vasos sanguíneos, tendo em vista que obteve acertos superiores a 93,9% na detecção para todos os casos. Além disso, a metodologia proposta foi capaz de ficar acima da média da metodologia de extração supervisionada e pouco abaixo da não supervisionada. Neste contexto, o tempo de execução do método proposto ficou menor em comparação ao método de extração supervisionado.

O método proposto foi capaz de reduzir a porcentagem de falsos positivos, embora o número de falsos negativos tenha ficado maior que a média encontrada na referência. Por isso, como trabalho futuro deseja-se aprimorar a metodologia de separação do fundo e limiarização, com o objetivo de elevar o número de acertos e reduzir o número de falsos negativos.

Agradecimentos

Este trabalho contou com o apoio do Núcleo de Assuntos Estudantis e Comunitários - NAEC do Instituto Federal do Norte de Minas Gerais (IFNMG) - *Campus Montes Claros*.

REFERÊNCIAS

- Bertholdo, F. A. R. (2007). Técnicas de limiarização para melhorar a qualidade visual de documentos históricos. Master's thesis, Universidade Federal de Minas Gerais.
- Consortium, I. C. (2004). Specification icc.1:2004-10: Image technology colour management — architecture, profile format, and data structure. All Rights Reserved: Icc, 2004.
- Cree, M. J., Gamble, E., and Cornforth, D. J. (2005). Colour normalisation to reduce inter-patient and intra-patient variability in microaneurysm detection in colour retinal images. pages 163–168.

- Daugman, J. G. (1980). Two-dimensional spectral analysis of cortical receptive field profiles. *Vision Research*, 20:847–856.
- de Oliveira, A. Q. (2013). Pré-processamento de imagens de fundo do olho: Correção de iluminação e de contraste para a identificação automática da rede de vasos. Monografia (Especialização) - Curso de Ciência da Computação, Universidade Federal do Pampa – Unipampa, Alegrete.
- Duda, R., Hart, P., and Stork, D. (2001). *Pattern Classification*. John Wiley and Sons. 0-471-05669-3.
- Facon, J. (2011). A morfologia matemática e suas aplicações em processamento de imagens. *VII Workshop de Visao Computacional – WVC 2011*, pages 61–128.
- Gazziro, M. and Borges, V. R. P. (2017). Quadro segmentação de imagens.
- Goatman, K. A., Whitwam, A. D., Manivannan, A., Olson, J. A., and Sharp, P. F. (2003). Colour normalisation of retinal images. In *Proceedings of Medical Image Understanding and Analysis*, pages 49–52.
- Gonzalez, R. and Woods, R. (2014). *Processamento Digital De Imagens*. Pearson Education, 3rd edition.
- MATLAB, P. (2017). *adaphisteq*. Acesso em 30 jul. 2017.
- Mendonca, A. M. and Campilho, A. (2006). Segmentation of retinal blood vessels by combining the detection of centerlines and morphological reconstruction. *IEEE transactions on medical imaging*, 25(9):1200–1213.
- Moreira, A. C. (2011). *Métodos para Segmentação Binária para Imagens em Tons de Cinza*. Universidade Federal de Santa Catarina, Florianópolis, P.O. Box 476, CEP 8040-900,PR, Brazil, 1 edition. ISSN 2178-4507.
- Neto, R. A. V. (2010). Morfologia matemática binária.
- Otsu, N. (1979). A threshold selection method from gray-level histograms. *IEEE transactions on systems, man, and cybernetics*, 9(1):62–66.
- Saleh, M. D., Eswaran, C., and Muen, A. (2011). An automated blood vessel segmentation algorithm using histogram equalization and automatic threshold selection. *Journal of Digital Imaging*, 24(4):564–572.
- Soares, J. V. B. (2006). Segmentação de vasos sanguíneos em imagens de retina usando wavelets e classificadores estatísticos.
- Staal, J., Abràmoff, M. D., Niemeijer, M., Viergever, M. A., and Van Ginneken, B. (2004). Ridge-based vessel segmentation in color images of the retina. *IEEE transactions on medical imaging*, 23(4):501–509.
- Welfer, D. (2011). Métodos computacionais para identificar automaticamente estruturas da retina e quantificar a severidade do edema macular diabético em imagens de fundo de olho.
- Wu, D., Zhang, M., Liu, J.-C., and Bauman, W. (2006). On the adaptive detection of blood vessels in retinal images. *IEEE Transactions on Biomedical Engineering*, 53(2):341–343.

IDENTIFICATION OF VESSELS FROM RETINAL IMAGES

Abstract. *This work presents an algorithm for blood vessel segmentation from retinal images which takes advantage of simple but powerful image processing techniques. The proposed algorithm uses the CIELAB color space to work on the luminance channel and presents an iterative method for contrast enhancement and a simple method for background extraction and image thresholding used in the binarization process. The results show that our methodology performs better or equivalent to others known methods in terms of accuracy and efficiency.*

Keywords: *Eye background image, Image Processing, Image Segmentation*